

# Unet 模型在分布式光伏组件检测中的实践与应用

2210273096 蔡昊杰

## 摘要

如今,可获得的全球光伏(PV, photovoltaic)发电组件数据具有以下几点问题:1. 光伏组件数据更新日益加快,而数据的更新却缺乏实时性;2. 大部分数据不公开面向研究组织和政治组织,开源的数据难以获取。同时,随着深度学习在遥感与目标分割领域的发展与应用不断加深,全球光伏发电数据可以应用深度学习的手段进行分析与预测。本次课程的论文复现工作拟通过对开源遥感影像数据进行获取处理,利用开源地理数据集构建合适的属于自己的影像数据集,采用 Unet 模型,来分割分布式光伏组件,探究实践了 Unet 对分布式光伏组件识别的可行性。

**关键词:** 深度学习; Unet; 分布式光伏组件; 图像分割;

## 1 引言

2020 年 9 月 22 日,中国国家主席习近平在第七十五届联合国大会一般性辩论大会上提出了中国要在 2030 年之前实现碳达峰、2060 年之前实现碳中和的目标(即“双碳”目标),在国内国际社会引发了广泛而热烈关注。次年,全国碳排放权交易市场正式启动上线交易,成为全球规模最大的碳市场。我国地域广阔,大部分地区太阳辐射照度较大,可以直接利用的太阳能资源非常丰富。太阳能作为一种清洁的、可再生的能源,利用光伏组件设备将太阳能转化为电能,对于降低我国在化石燃料方面的依赖程度和实现双碳目标具有重要意义。

2021 年, Nature 接收了 KRUITWAGEN L 在全球光伏设备检测领域的论文<sup>[1]</sup>, 论文作者耗费近 3 年,在笛卡尔实验室云计算平台的帮助下用了两万个 GPU 小时实现了创新的双分支(2-Branch)模型,利用 SPOT 和 Sentinel-2 卫星图像,检测出了截至 2018 年的全球光伏设备分布情况,并释放出了带地理信息的开源 geojson 格式数据,解决了当时全球光伏设备分布情况、分布地理区域等几大问题。

## 2 相关工作

本节主要对课题内容的相关工作进行简要的分类概括与描述,将从 GEE 平台在线处理数据、构建属于自己的数据集和将 Unet 应用于光伏组件检测三个方面进行描述和介绍。

### 2.1 基于 GEE 的遥感影像处理

Google Earth Engine(GEE)是由 Google 开发的新一代基于云的地球科学数据和分析应用行星尺度平台,主要应用于地球科学数据,尤其是遥感影像数据的可视化计算和分析。目前 GEE 平台提供了大概 600 多种地球科学数据集。因此,在无法获得原论文中所用数据集的情况下,采用从 GEE 平台下载处理得到的数据集来进行训练是可行的。因此,我尝试通过 GEE 平台来对原论文作者给出的数据集进行处理,以便得到模型可用的数据集。

基本步骤主要分为五步,第一步格式数据转化,转化为矢量格式;第二步地理定位镶嵌(Mosaic)处理,转化为一景影像,第三步去云(Opaque clouds 不透明的云和 Cirrus clouds 卷云),消除云层对面板检测的影响,第四步,重投影,恢复原本的分辨率,第五步图像剪裁,下载到本地。

2.2 构建数据集

我通过上述步骤，对 BRADBURY K<sup>[2]</sup>发布的数据进行了剪裁，构建出了适合分布式光伏组件的数据集，并通过传统图像处理方法将数据集从 100 多张影像扩充到了 600 张影像，并利用该数据集对模型进行训练和评估。

2.3 基于 Unet 模型的图像分割

Unet 在图像分割领域的应用已有近八年的时间了，在遥感领域也是如此，随着深度学习在遥感领域应用越来越广泛，Unet 在遥感领域也成为了一项成熟而经典的检测模型。

3 本文方法

3.1 本文方法概述

UNet 是一个很经典的深度学习模型，它最早发表在 2015 的 MICCAI 上，主要应用在医学图像的分割中。医学影像的特点是前背景信息简单，信息较为单一不复杂，UNet 这样的小规模深度模型在医学影像的识别中效果一直表现优异，我采用 Unet 进行模型复现的原因在于原论文作者也在其双分支模型中用到了 Unet 来进行图像分割，而我之前并未接触过深度学习，因此选择从简单而经典的模型入手，抛砖引玉，后面再逐步实现原论文中用到的双分支模型。

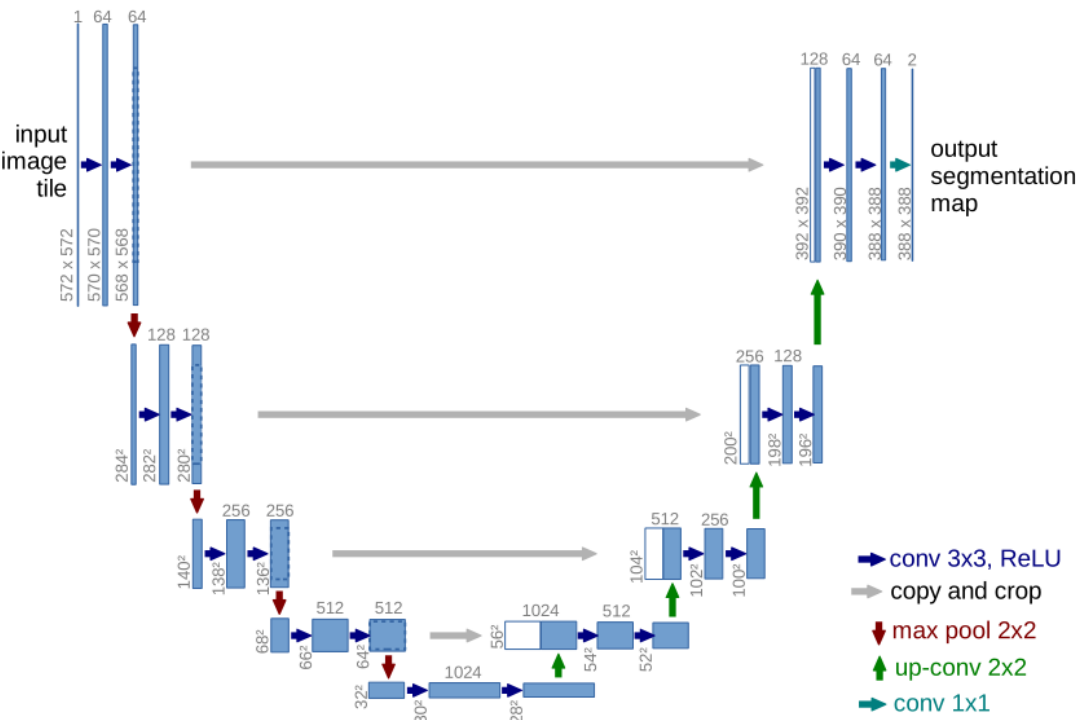


图 1: Unet 结构示意图

3.2 影像分割模块

UNet 的整个模型类似字母 U 的形状，它主要包括两个组成部分，左边部分为编码器 (Encoder)，采用了 4 个池化层，在不断下采样的过程中不断的降低分辨率以获得不同尺度的图像信息，图像的信息由粗浅的点、线、面、梯度等信息逐渐向高程信息中的轮廓以及更抽象更加高维度的特征信息转变，在这个过程中，网络的通道数 (channel) 会逐渐增大，而图像的长和宽逐渐减小，最后变成包含特征信息极其丰富的特征图像。由此，整个网路完成了“由细到粗”特征的提取与组合，使 UNet 得到的信息更加全面。

右边部分则为解码器 (Decoder)，负责图像特征的还原，将图像的长宽变回最开始的比例，还原最初形状的身影，从而能够做到每个像素的分割并对分割效果进行评估。整个网络实际上就是一个编码-解码器结构。在编码 (encode) 的过程中，部分信息丢失了 (Maxpooling 和 Conv2D)，这样就会导致在 decoder 中上采样过程中就失去了对细节信息的敏感。在解码时，我们要加入与之对应的 encoder 层信息，即跳跃连接结构 (skip connection)，将同层高度中的 encoder 内的更低维度、更细节的点线面等信息直接 Concat 到对应 decoder 结构中去，从而使得 UNet 获得更准确的分割结果

### 3.3 损失函数定义

由于光伏面板检测分类仅仅分类前景 (光伏组件) 和背景，所以可以采用二分类交叉熵来作为损失函数，作为衡量预测的输出图像每个像素和真实标签 (label) 中每个像素的距离度量。值得注意的是，最后我在二分类交叉熵 `torch.nn.BCEWithLogitsLoss()` 最后添加了 `sigmoid()` 函数，`sigmoid()` 函数的应用，使得前背景类别概率差异变得更加显著，最大值产生的概率更接近 1，这样输出分布的形式更接近真实分布。从而得到输出值 *outputs*。

$$Loss = -[y_0 \log \hat{y}_0 + (1 - y_0) \log(1 - \hat{y}_0)] \quad (1)$$

$$outputs(x_i) = \frac{1}{1 + e^{-x_i}} \quad (2)$$

## 4 复现细节

### 4.1 与已有开源代码对比

本篇文章没有参考任何相关源代码。由于打算复现的论文<sup>[1]</sup>是基于美国笛卡尔实验室提供的模型接口进行代码编写和遥感影像处理，而该实验室我没有权限使用；同时，原论文作者用的 SPOT 遥感卫星影像数据属于法国空间研究中心，数据也难以获取。因此我根据原论文的思路，结合 xxx 发布的开源数据<sup>[2]</sup>自己制作出了训练用的数据集，对原论文模型中的部分结构进行了实现，即基于 Unet 模型的结构<sup>[3]</sup>自己编写了基于 Pytorch 的模型代码。

Unet 模型的伪代码如下所示：

---

**Procedure 1** U-net Model for PV Panel Detecting.

---

**Input:** image  $X(3*200*200)$

**Output:** binary prediction image  $Outputs(2*200*200)$

$C_0 = X$

**for**  $i$  **in** 4 **do**

$C_i = \text{Conv}(P_i)$        $P_i = \text{Pool}(C_i)$

**end**

$C_4 = \text{Conv}(P_3)$

**for**  $i$  **in** 4 **do**

$UP_i = \text{up}(C_{4+i}, k_i)$        $\text{merge}_i = \text{cat}(UP_i, C_{4-i})$        $C_{4+i} = \text{Conv}(\text{merge}_i)$

**end**

$C_9 = \text{Conv}(C_8)$   $Outputs = \text{Sigmoid}(C_9)$

---

### 4.2 实验环境搭建

本次论文复现工作主要有两个实验环境：第一个是谷歌地球引擎 GEE 平台，通过该平台上传指定的矢量文件，在线选择卫星类型、识别、处理并下载所需的对应遥感数据。第二个平台是实验室提

供的服务器，在该服务器上配置 python3.9 环境，并在该环境下进行模型的代码编写和训练，成功实现了这一简单的模型复现。

### 4.3 GEE 遥感影像处理

首先，第一步是将 geojson 格式数据转化为矢量格式的 shp 格式数据，因为 GEE 平台只能接收和识别 shp 格式数据并转化为要素集合 (FeatureCollection)；接着第二步通过 GEE 平台获取数据的地理坐标，使用地理坐标来定位出 Sentinel-2 卫星在 2022-03-01 至 2022-10-01 之间所有的重叠的一景影像，接着对这些影像集合 (ImageCollection) 进行镶嵌 (Mosaic) 处理，以将其转化为一张一景影像 (Image)；第三步对镶嵌后的一景影像，利用 Sentinel-2 的 QA60 波段进行去云 (Opaque clouds 不透明的云和 Cirrus clouds 卷云) 处理，消除云层对光伏面板检测的影响；第四步，由于镶嵌后的图像投影的名义分辨率 (nominalScale) 会发生变化，因此要图像进行重投影，在重投影的过程中去将分辨率修改成原本的分辨率；第五步对去云后的图像进行剪裁，用转化后的 shp 格式将研究区域 ROI(Region Of Interest) 剪裁出来，然后下载到本地。




图 2: GEE 平台去云前与去云剪裁后

### 4.4 USGS 影像处理和数据集展示

在本地，USGS 数据集<sup>[2]</sup>主要的处理思路是将 geojson 格式转化为 json 格式，json 格式是数据分析等领域的常用数据格式，因此很容易能够利用 json 格式结合 python GDAL 程序，采用滑动窗口策略批量剪裁光伏面板的数据集。



图 3: Image 展示

剪裁完成后，对规模较小的数据集进行数据增强，主要是利用 Python 地理库 GDAL 对遥感图像



进行几何变换，包括翻转、旋转、移位、变形和缩放等各类操作。图三中展示了经过数据增强后的规模较大的数据集。




图 4: 数据增强操作

在获得了规模较大的数据集之后，要对 label 进行制作，label 的制作主要通过 cv2 和 GDAL 进行处理，首先是要对 TIFF 格式的遥感影像进行读取，接着对影像进行 mask 操作，将不需要的背景信息都赋值为 0，而需要的前景信息 (PV 组件) 都赋值为 1，便于与后续输出影像的对比以及 Loss 的计算，对整个模型做出客观准确的评价。



图 5: Label 展示

4.5 模型预测结果展示与分析

通过对模型进行训练，将模型的 Loss 函数训练至收敛，最终模型的 Loss 可以收敛到 0.02，模型在训练集上的表现也很好，当然本数据集由于是自己制作的，所以样本量较小，只有 600 余张，因此模型自然在训练集上表现会很好。下面两图 (图-) 展示了最终模型 Loss 下降至收敛的过程：




图 6: 训练集训练至收敛

```
98-0-train_loss==>>0.00385898444801569
98-10-train_loss==>>0.017403751611709595
save weight successfully
99-0-train_loss==>>0.002862930530682206
99-10-train_loss==>>0.00202026660554111
save weight successfully
```

图 7: 训练集 Loss 结果展示

下图展示了模型在训练集影像上的分割效果：



图 8: 训练集分割效果展示

将训练好后的模型对测试集进行测试，测试集包含 50 张影像，全是不包含在训练集中的，即模型之前没见过的影像，从而客观的衡量模型表现。下图展示了模型在测试集的分割效果：




图 9: 测试集分割效果展示

下图展示了模型在测试集上 50 张影像上的 Loss 结果：




图 10: 测试集 Loss 结果展示

#### 4.6 创新点

自己对数据集进行了处理下载而没有采用现成的数据集。

### 5 实验结果分析

通过观察模型在测试集上的表现结果，可以发现模型的泛化能力比较差，思考原因主要有以下两点：1. 由于数据集较小，可能导致模型对训练集的影像过拟合，从而在测试集上表现较差；2. 遥感影像的特点是背景信息复杂、地物信息复杂，光伏组件周围可能存在各种各样的物体，他们的光谱也有可能类似于 PV 设备的光伏成分，而我的数据集主要采用了三通道 (RGB) 影像，未来应当考虑加入其他的波段，更换成多光谱图像，从而提高分割效果。

此外，模型对 PV 组件的分割在边缘等地方表现也一般，经过查阅相关文献<sup>[4]</sup>，对于分割结果中

边缘模糊、相邻光伏板容易粘附问题，可以考虑引入结合边缘检测网络和语义分割网络进行多任务学习，精细化地提取光伏板边界。

## 6 总结与展望

我在 GEE 上的处理方法对于自己给定的地理坐标可以将图片下载到本地，但是原论文给定的 shp 格式下载下来遇到了形变等问题，初步考虑是地理坐标转换或是地图投影的标准不同引起的，具体原因还没有研究出来，因此后面选择多剪裁了 BRADBURY K<sup>[2]</sup>发表的数据来作为训练样本，而没有采用原论文内给出的数据。未来展望希望能够将原论文给的数据集下载到本地，这样也能够将数据集的容量扩充到更大 (约 18570 张)，并对原论文内实现的双分支模型进行完全的复现，使图像分割的效果更加精确；后期也考虑也将图像的波段数扩充到 5-6 个波段，因为近红外波段 (NIR) 等其他几个波段都在遥感领域，特别是分割和检测方面有比较大的作用。

## 参考文献

- [1] KRUITWAGEN L, STORY K, FRIEDRICH J, et al. A global inventory of photovoltaic solar energy generating units[J]. Nature, 2021, 598(7882): 604-610.
- [2] BRADBURY K, SABOO R, L JOHNSON T, et al. Distributed solar photovoltaic array location and extent dataset for remote sensing object identification[J]. Scientific data, 2016, 3(1): 1-9.
- [3] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation. 2015.
- [4] JIE Y, JI X, YUE A, et al. Combined multi-layer feature fusion and edge detection method for distributed photovoltaic power station identification[J]. Energies, 2020, 13(24): 6742.